Propuesta de Proyecto

Predicción de ocurrencia y profundidad de inundaciones fluviales en Antioquia mediante redes neuronales

Saidy Julieth Bonilla Cachaya 1075790109

Sebastian Hernando Campino Figueroa 1018504452

Kevin Julian Gonzalez Guerra 1001185426

Cesar Fabian Rincon Robayo 1006535069

Universidad Nacional de Colombia - Sede Bogotá

Facultad de Ingeniería

Redes Neuronales

Luis Fernando Nino Vasquez

24 de febrero de 2026

PROJECT GOAL AND SCOPE

En este proyecto, nos proponemos desarrollar un modelo basado en inteligencia artificial capaz de predecir si un municipio del departamento de Antioquia experimentará una inundación fluvial en un horizonte de 24 horas. Nuestra meta principal es que el sistema aprenda a reconocer patrones complejos entre la precipitación reciente y las características físicas del terreno para emitir alertas antes de que ocurra el desastre; adicionalmente, buscamos implementar un enfoque avanzado que permita estimar la profundidad de la inundación en las zonas de mayor susceptibilidad.

Desde una perspectiva técnica, el proyecto evaluará y comparará dos arquitecturas de redes neuronales: una red neuronal superficial (Shallow NN), utilizando un Perceptrón Multicapa (MLP) como línea base interpretable, y una red neuronal profunda (Deep NN) basada en celdas de Memoria de Largo Corto Plazo (LSTM),,. Esta comparativa nos permitirá cuantificar la ganancia en precisión al capturar dependencias temporales y espaciales, además de evaluar la capacidad explicativa de los modelos para entender qué variables influyen con mayor peso en el desbordamiento de los ríos,.

Nuestro alcance comprende el procesamiento de un conjunto de datos multivariados que incluye registros de precipitación del IDEAM con resolución de 10 minutos, variables climáticas como temperatura y humedad, y factores geográficos derivados de modelos digitales de elevación (altitud, pendiente y distancia a ríos),,. Geográficamente, el estudio se limita al departamento de Antioquia, Colombia, con especial énfasis en los municipios ribereños de los ríos Magdalena, Cauca, Atrato y Nechí, utilizando registros históricos de eventos reales comprendidos entre los años 2018 y 2025. Con esto, pretendemos demostrar que es posible

construir modelos predictivos de alta calidad utilizando exclusivamente fuentes de datos abiertos nacionales e internacionales.

LITERATURE REVIEW

Para esta revisión de literatura, seleccionamos diversos artículos con el propósito de establecer una base técnica y científica que sustenta nuestro proyecto de predicción de inundaciones en Antioquia. El análisis se estructuró partiendo del contexto de la problemática en Colombia, pasando por los factores de entrada necesarios y comparando las arquitecturas de redes neuronales desde enfoques superficiales hasta modelos de aprendizaje profundo y su interpretabilidad.

Las inundaciones constituyen uno de los desastres naturales más recurrentes en Colombia. Eventos extremos asociados al fenómeno de La Niña han afectado a millones de personas y generado impactos significativos sobre el PIB nacional. En este contexto, se ha señalado que las técnicas de inteligencia computacional representan una alternativa viable en cuencas como la del río Magdalena, especialmente cuando no se dispone de modelos hidrodinámicos complejos para la predicción de niveles de agua [1]. Asimismo, estudios aplicados a ríos colombianos como el Arauca muestran que los modelos basados en inteligencia artificial superan a las regresiones lineales tradicionales, logrando sistemas de alerta temprana más confiables y precisos [2].

Respecto a la preparación de la información, la literatura coincide en que la modelación de inundaciones requiere la integración de variables geográficas y climáticas. Entre los factores más relevantes se encuentran la altitud, la pendiente, el uso del suelo, el índice de vegetación (NDVI) y la precipitación acumulada [3]. La combinación de estos atributos permite capturar

patrones espaciales y físicos que incrementan la susceptibilidad a inundaciones antes de que ocurra el evento.

Para una primera aproximación metodológica, se han considerado modelos de redes neuronales superficiales. Comparaciones entre Perceptrón Multicapa (MLP), sistemas neuro-difusos (ANFIS) y máquinas de soporte de vectores (SVM) evidencian que el MLP ofrece un balance adecuado entre simplicidad de implementación y desempeño predictivo, además de requerir menor costo computacional [1]. No obstante, cuando el problema implica capturar dependencias temporales propias de series climáticas, la literatura sugiere emplear arquitecturas de aprendizaje profundo. En particular, las redes de Memoria de Largo Corto Plazo (LSTM) han demostrado superar modelos estadísticos tradicionales como ARIMA en la predicción de precipitación en departamentos como Boyacá, reproduciendo patrones complejos con errores significativamente menores [4].

En aplicaciones más avanzadas de entornos urbanos, se ha explorado arquitecturas híbridas para abordar simultáneamente componentes espaciales y temporales. La combinación de Redes Neuronales Convolucionales (CNN) con redes LSTM bidireccionales (BiLSTM) permite extraer características espaciales del terreno y procesar secuencias meteorológicas de manera integrada, mejorando la clasificación del riesgo de inundación [5]. De forma complementaria, la arquitectura R2RNet utiliza imágenes de radar junto con capas convolucionales para transformar datos de lluvia en predicciones precisas del nivel de los ríos, evidenciando el potencial de los enfoques basados en datos espaciales de alta resolución [6].

Finalmente, un punto crítico que abordamos en nuestro proyecto es la transparencia de los modelos. Tradicionalmente, las redes profundas han sido vistas como "cajas negras", sin embargo, el método de Mapas de Activación de Clase Pesados por Gradiente (Grad-CAM) ha

sido implementado como una estrategia para mejorar su interpretabilidad [7]. Esta técnica permite abrir la caja negra de una CNN, identificando cuantitativamente qué variables de entrada, como la precipitación en horas específicas, tuvieron mayor peso en la predicción final de una inundación.

CASE STUDY

Para el desarrollo de este proyecto, hemos identificado estudios de caso clave que representan soluciones parciales y avances metodológicos fundamentales hacia nuestra meta de predecir inundaciones en Antioquia.

Caso de Estudio 1: Arquitectura predictiva LSTM en cuencas tropicales

- **Identificación y citación:** El primer avance clave se reporta en el artículo "Estimación de caudales en una cuenca tropical mediante modelación neuronal artificial basada en memoria hidrológica", publicado en la revista *Ingeniería y Competitividad*. **[8]**
- **Avance metodológico:** Esta investigación desarrolla un modelo neuronal basado en Redes LSTM (Long Short-Term Memory) aplicado a la predicción del caudal en un río tropical. Para el entrenamiento del modelo, se utilizaron miles de registros diarios correspondientes a humedad, temperatura y precipitación.
- **Justificación de utilidad para el proyecto:** Este artículo constituye el estado del arte actual en Colombia sobre la materia. Su utilidad directa para nuestro proyecto se basa en que la red neuronal demostró una altísima capacidad predictiva, logrando una correlación de hasta 0.98 al ser capaz de "recordar" patrones del pasado y capturar la influencia de fenómenos climáticos como El Niño y La Niña. Esta investigación justifica nuestra metodología, ya que representa exactamente la arquitectura que se intenta replicar para los ríos de Antioquia.

Caso de Estudio 2: Relación funcional de factores espaciales a nivel local

- **Identificación y citación:** El segundo avance se encuentra documentado en el estudio local "Geotechnical zonification of the Valle de Aburrá using artificial neural network".**[9]**
- **Avance metodológico:** Es un trabajo investigativo que utiliza de manera explícita una Red Neuronal Artificial (RNA). El modelo de este estudio fue entrenado utilizando la precipitación (lluvia) como el factor detonante, sumado a cinco factores de entrada específicos: terreno, geología, geomorfología, uso del suelo y pendiente.
- **Justificación de utilidad para el proyecto:** Este estudio es vital para nuestra investigación porque evidencia cómo una red neuronal logra mapear la relación funcional no lineal existente entre dichos factores geográficos y la probabilidad de que ocurra un desastre por agua o tierra. Esto sustenta nuestra selección de variables físicas del terreno como entradas válidas para predecir la susceptibilidad a inundaciones en la región.

TRAINING DATA SET

Se utilizará un conjunto de datos multifuente y multiescala para entrenar los modelos de redes neuronales propuestos. La idea es capturar la relación entre la precipitación reciente, las condiciones físicas del territorio y la ocurrencia de inundaciones fluviales en municipios del departamento de Antioquia, Colombia.

La construcción del dataset responde directamente al objetivo de esta propuesta, que consiste en predecir si un municipio experimentará una inundación fluvial en las próximas 24 horas, y posteriormente estimar la profundidad de inundación mediante un enfoque más avanzado.

El conjunto de datos se compone de cinco grandes bloques: información hidrometeorológica, variables meteorológicas complementarias, datos satelitales, variables topográficas y de uso del suelo, y registros históricos de inundaciones que sirven como variable objetivo.

Inventario consolidado de datos disponibles

Categoría	Fuente	Cobertura temporal	Resolución	Uso en el modelo
Precipitación	IDEAM	2018 - 2025	10 minutos	Variable principal para acumulados (6h, 12h, 24h, 48h, 3d, 7d, 15d)
Estaciones	IDEAM	IDEAM	-	Coordenadas y clasificación de estaciones (437 hidrométricas en Antioquia)
Nivel del río	IDEAM	2018 - 2025	Variable según estación	Variable objetivo auxiliar / validación hidrológica
Caudal	IDEAM	2018 - 2025	Variable según estación	Relación lluvia/respuesta fluvial
Variables meteorológicas	Open-Meteo	2018 - 2024	Horaria	Variables contextuales (temperatura, humedad, viento)
Precipitación satelital	CHIRPS	1981 - presente	Diaria, 0.05°	Complemento en zonas sin estación
Imágenes radar	Sentinel-1 (GEE)	2017 - 2022	~10 m	Detección espacial de áreas inundadas
Modelo digital de elevación	SRTM (IGAC)	Estático	30 m	Elevación y pendiente
Red hidrográfica	IGAC	Estático	02:40.0	Distancia a ríos

Cobertura del suelo	MapBiomas	2018 - 2024	30 m	Porcentaje de impermeabilidad / clase dominante
Emergencias históricas	DAGRAN	1903 - 2025	Evento puntual	Etiquetado histórico
Ground truth filtrado	DAGRAN	2018 - 2025	Evento por municipio	Variable objetivo binaria
Profundidad de inundación	IDEAM	Estático (escenarios)	Polígonos	Clasificación multiclase (Fase 2)
Amenaza de inundación	IDEAM	Estático	Polígonos	Validación espacial
Eventos nacionales	UNGRD	2016 - 2025	Evento puntual	Verificación cruzada

1. Datos hidrometeorológicos - IDEAM

Se emplearán registros oficiales del Instituto de Hidrología, Meteorología y Estudios Ambientales (IDEAM), incluyendo precipitación, nivel del río y caudal en estaciones estratégicas del departamento.

El uso de precipitación y nivel hidrométrico como variables principales es evidenciado en estudios como Moreno et al. [1], quienes modelaron inundaciones en el río Magdalena mediante técnicas de inteligencia computacional usando niveles diarios y variables hidrológicas. De manera similar, Cárdenas-Rodríguez et al. [2] desarrollaron un sistema de alerta temprana para el río Arauca utilizando precipitación y nivel como entradas fundamentales.

Estas investigaciones demuestran que la relación lluvia/respuesta fluvial es adecuada para el modelado predictivo en el contexto colombiano.

2. Variables meteorológicas complementarias

Se incorporan temperatura, humedad relativa y velocidad del viento descargadas mediante Open-Meteo. Estos datos pueden enriquecer la representación del estado atmosférico.

En modelos profundos espacio-temporales, la integración de múltiples variables meteorológicas mejora la capacidad de aprendizaje de patrones complejos, como se evidencia en arquitecturas recientes para pronóstico de nivel de agua [6].

3. Datos satelitales - CHIRPS y Sentinel-1

3.1 Precipitación satelital CHIRPS

CHIRPS se utilizará como complemento a las estaciones del IDEAM, especialmente en zonas donde la cobertura de las estaciones del IDEAM es limitada. Contar con series de precipitación consistentes y continuas es fundamental para el modelado temporal, ya que la lluvia es el principal causante de los crecimientos fluviales. Algunos estudios recientes en Colombia han mostrado que las redes LSTM aplicadas a series de precipitación permiten capturar patrones temporales y mejorar la predicción hidrometeorológica [4].

Asimismo, arquitecturas profundas espacio-temporales han mostrado mejoras significativas cuando se alimentan con entradas pluviométricas bien estructuradas [6].

3.2 Imágenes SAR Sentinel-1

Las imágenes radar Sentinel-1 permiten identificar áreas inundadas incluso en presencia de nubosidad. La integración de información espacial y temporal en modelos híbridos ha demostrado mejorar la predicción de inundaciones [5], y enfoques convolucionales han evidenciado que incorporar patrones espaciales relevantes aumenta la precisión y facilita la interpretación del modelo [7].

4. Topografía y contexto físico del territorio

Se incorporan variables derivadas del modelo digital de elevación SRTM y de la red hidrográfica nacional:

- Altitud.
- Pendiente.
- Distancia a ríos.

La relevancia de variables topográficas en el modelado de susceptibilidad a inundaciones se evidencia por ejemplo en Bui et al. [3] donde demostraron que factores como elevación y pendiente influyen significativamente en la probabilidad de ocurrencia de inundaciones en modelos basados en aprendizaje automático.

Estas variables permiten incorporar el condicionamiento geomorfológico del territorio.

5. Cobertura del suelo

La clasificación de cobertura del suelo (MapBiomas) permite estimar niveles de impermeabilidad y uso predominante del territorio.

La combinación de variables topográficas y uso del suelo mejora el desempeño de modelos de susceptibilidad a inundaciones, como por ejemplo se evidencia en estudios basados en técnicas híbridas de aprendizaje automático [3].

6. Ground truth de inundaciones

El componente más importante del dataset es nuestra variable objetivo.

Actualmente se cuenta con lo siguientes datos:

- 11,373 registros históricos de emergencias en Antioquia desde 1903.
- 1,940 registros clasificados como inundaciones.
- Un subconjunto limpio de aproximadamente 2,496 eventos hídricos entre 2018 y 2025.
- 56,905 polígonos oficiales del IDEAM de profundidad de inundación para diferentes períodos de retorno (TR10, TR20, TR50 y TR100).
- Polígonos de eventos históricos asociados a fenómenos de La Niña.

El uso de eventos históricos etiquetados como variable objetivo es consistente con el enfoque aplicado en los estudios del río Magdalena y del río Arauca [1], [2], donde los modelos aprenden la relación entre lluvia antecedente y ocurrencia de crecidas.

7. Estructura y preprocesamiento

Las series temporales se organizarán por municipio y fecha, lo que permitirá plantear el problema como una tarea de clasificación supervisada. En la primera fase, la variable objetivo será binaria:

Y = 1 si se registra una inundación en las siguientes 24 horas, y

Y = 0 en caso contrario.

En la segunda fase, el modelo deberá clasificar la profundidad estimada de la inundación en distintas categorías.

Antes del entrenamiento, los datos pasarán por un proceso de preparación que incluirá la depuración de fechas y registros inconsistentes, la construcción de acumulados temporales de precipitación, el cruce espacial entre estaciones, municipios y polígonos de inundación, la normalización de variables y, cuando sea necesario, el balanceo de clases.

La combinación de información temporal y espacial es coherente con el uso de arquitecturas como LSTM y otros modelos espacio-temporales profundos, que han mostrado mejoras significativas en la predicción de eventos de inundación [5] - [7].

PROPOSED NEURAL NETWORK BASED APPROACH

El proyecto implementa dos enfoques comparables que responden a la misma pregunta de predicción:

Fase 1 — Shallow Neural Network (entrega intermedia)

> Pregunta: ¿Dado lo que ha llovido en las últimas horas en este municipio, va a inundarse en las próximas 24 horas?

Arquitectura: Perceptrón Multicapa (MLP) con 2 a 3 capas ocultas y activación ReLU.

Tipo de problema: Clasificación binaria: inundación (1) / no inundación (0).

Variables de entrada por punto/evento:

- Precipitación acumulada en ventanas de 6h, 12h, 24h y 48h previas (IDEAM)

- Temperatura promedio y humedad relativa (Open-Meteo)
- Elevación media del municipio derivada del DEM SRTM
- Porcentaje de cobertura impermeable del suelo (MapBiomas)
- Distancia al río más cercano (derivada de la red hidrográfica IGAC)

Variable objetivo (Y): 1 si el DAGRAN reportó inundación en ese municipio en las 24h siguientes, 0 si no.

Justificación: El MLP es el modelo base exigido por el profesor como base interpretable. Su simplicidad permite identificar qué variables tienen mayor peso predictivo antes de pasar a arquitecturas complejas.

Fase 2 — Deep Neural Network (entrega final)

> Pregunta: ¿Dado lo que ha llovido y el contexto espacial del territorio, dónde exactamente y con qué profundidad se inundará?

Arquitectura: Red LSTM (Long Short-Term Memory) para capturar dependencias temporales en las series de precipitación, complementada con features espaciales del DEM y la cobertura del suelo.

Tipo de problema: Clasificación multiclase de profundidad de inundación: <0.5m / 0.5 - 1.0m / 1.0-1.5m / >1.5m.

Variables de entrada:

- Series temporales de precipitación horaria por estación IDEAM (entrada secuencial al LSTM)
- Imágenes SAR Sentinel-1 (bandas VV y VH) para el período analizado
- DEM SRTM: elevación, pendiente, distancia a ríos
- Cobertura del suelo MapBiomas: clase de uso e impermeabilidad

Variable objetivo (Y): Categoría de profundidad de inundación según los polígonos TR10/TR20/TR50/TR100 del IDEAM.

Justificación: El LSTM es la arquitectura estándar para series temporales hidrológicas. Estudios colombianos recientes (río Tuluá, 2025; Boyacá, 2024) demostraron correlaciones de hasta 0.98 con esta arquitectura usando datos similares a los nuestros.

Atributo	Shallow NN (Fase 1)	Deep NN (Fase 2)
Problema	Clasificación binaria (inundación sí/no)	Clasificación de profundidad (4 clases)
Arquitectura	MLP — 2-3 capas ocultas	LSTM + features espaciales
Entrada	Vector tabular por evento	Secuencia temporal + contexto espacial
Salida	Probabilidad de inundación por municipio	Mapa de profundidad por zona
Ground truth	DAGRAN 2018 - 2025	Polígonos TR IDEAM (56,905 polígonos)
Ventaja	Interpretable, rápido de entrenar	Capta patrones temporales complejos (profundidad del agua)

EXPECTED RESULTS

Se esperan los siguientes resultados cuantitativos y cualitativos, de acuerdo a las fases (modelo 1 y 2):

Fase 1: Shallow NN: El MLP debería alcanzar una precisión de clasificación (binaria) superior al 75% en el conjunto de prueba, con un F1-score aceptable para la clase positiva (inundación). Servirá como línea base para comparación.

Fase 2: Deep NN (LSTM): Se espera una mejora significativa en todas las métricas respecto al MLP, consistente con lo reportado en estudios similares en Colombia (R^2 hasta 0.98). La red

debería capturar correctamente el efecto de la lluvia acumulada en días anteriores sobre el nivel de los ríos.

Resultado principal: Demostrar que con datos abiertos colombianos (IDEAM, DAGRAN, MapBiomas) es posible construir un modelo predictivo de inundaciones con calidad comparable a estudios internacionales, sin necesidad de datos propietarios.

EVALUATION OF THE SOLUTION

La evaluación del modelo combinará métricas estándar empleadas en modelado hidrológico con métricas propias de clasificación supervisada, dado que el proyecto contempla tanto predicción de variables continuas como detección de eventos de inundación.

Para variables continuas como nivel del río o profundidad estimada, se emplearán:

- RMSE (Root Mean Square Error) y MAE (Mean Absolute Error) para cuantificar la magnitud del error.
- R^2 (Coeficiente de determinación) para evaluar la proporción de varianza explicada.
- NSE (Nash - Sutcliffe Efficiency), utilizado en hidrología para validar modelos de series temporales [1], [6].

En la Fase 1, donde el problema se formula como clasificación binaria (inundación sí/no), se utilizará:

- F1-score, debido al desbalance natural entre eventos y no eventos, uso evidenciado en modelos de predicción de inundaciones basados en aprendizaje profundo [5], [7].

Los datos se dividirán de manera cronológica en conjuntos de entrenamiento, validación y prueba. Esto permite evitar el uso de información futura durante el entrenamiento y reproduce un escenario real de pronóstico a 24 horas, como se hace en algunos estudios de predicción hidrológica con redes neuronales [4], [6].

Por último los modelos propuestos (MLP y LSTM) se compararán con enfoques más simples, como un modelo de persistencia y una regresión logística. Esta comparación permitirá evaluar si las redes neuronales realmente ofrecen una mejora significativa en la predicción de inundaciones, como se ha reportado en investigaciones recientes en el área [5], [6].

ETHICAL CONSIDERATIONS/QUESTIONS

Al abordar este proyecto, nos hemos planteado preguntas críticas sobre el proceso de desarrollo y el impacto potencial de nuestras soluciones en las comunidades vulnerables de Antioquia. A continuación, analizamos nuestro proyecto bajo los principios éticos fundamentales de la investigación:

1. Confidencialidad y Anonimato en el Uso de Datos Aunque nuestro proyecto se basa en fuentes de datos abiertos (IDEAM, CHIRPS, SRTM), también utilizamos registros históricos de emergencias proporcionados por el DAGRAN y la UNGRD para etiquetar nuestra variable objetivo. Éticamente, es imperativo asegurar que estos datos se procesen de manera estrictamente agregada (a nivel municipal o de cuenca). Debemos garantizar que en ninguna etapa del procesamiento se exponga o infiera información de identificación personal de los damnificados por eventos pasados, manteniendo el enfoque exclusivamente en el comportamiento de las variables hidrometeorológicas y geográficas.

2. Potencial de Daño (Impacto de las Predicciones) Esta es la consideración ética más delicada de nuestro sistema. Las predicciones generadas por nuestro modelo tienen

implicaciones directas en la vida y el patrimonio de las personas. Nos planteamos dos escenarios críticos:

- **El riesgo de los falsos negativos:** Si el modelo falla al predecir una inundación inminente, podría generar una falsa sensación de seguridad, provocando que las autoridades y comunidades no evacuen a tiempo, lo que resultaría en un daño irreparable.
- **El riesgo de los falsos positivos:** Emitir alertas de inundación que no ocurren puede generar pánico injustificado, desgaste logístico y económico en los sistemas de emergencia, y lo más grave: el efecto "Pedro y el Lobo", donde las comunidades pierden la confianza en las alertas futuras. Para mitigar esto, nuestro diseño de investigación establece estrictamente que este modelo se concibe como una **herramienta académica y de soporte a la toma de decisiones**, la cual no pretende sustituir en ningún momento los canales oficiales de alerta temprana del Estado (como el IDEAM o el SIATA).

3. Transparencia y Comunicación de los Resultados Al utilizar redes neuronales profundas, nos enfrentamos al dilema ético de la "caja negra". Es éticamente cuestionable emitir una alerta de evacuación si no podemos explicar qué variables detonaron dicha alerta. Por ello, el proyecto contempla la interpretabilidad de los modelos (por ejemplo, a través del entendimiento de pesos en el MLP o metodologías de mapas de activación) para poder comunicar de forma transparente *por qué* se llegó a una predicción. Además, los resultados deberán comunicarse dejando claras las limitaciones del modelo, especialmente los sesgos de datos en regiones de Antioquia con escasa cobertura de estaciones de monitoreo, donde el margen de error podría ser mayor.

4. Participación Voluntaria y Consentimiento Informado Dado que nuestro proyecto utiliza datos observacionales, satelitales y registros institucionales, no interactuamos directamente con

sujetos de investigación humanos durante el entrenamiento de la red. No obstante, reconocemos que en una eventual fase de despliegue real en el futuro, las comunidades ribereñas a los ríos Cauca, Magdalena o Nechí tendrían que ser partícipes informados sobre cómo funciona esta tecnología, garantizando que el uso de la IA sea comprendido y aceptado por los usuarios finales y no impuesto como una medida tecnológica opaca.

CONTRIBUTIONS OF THE TEAM MEMBERS

Team Member	Rol(es)	Activities/contributions
Saidy Julieth Bonilla Cachaya	Lideresa	● Aporte con investigación de artículos científicos, periodísticos y obtención de algunas fuentes de datos como las de datos abiertos. ● Refacción de objetivo, alcances y literatura ● Finalmente, grabación del video de 2 minutos sobre el proyecto.
Sebastian Hernando Campino Figueroa	Coordinador, observador	● Aporte con ideas a el caso de estudio seleccionado ● Colaboré con revisión de literatura, revisión de datos disponibles. ● Aporté en la redacción de la sección de TRAINING DATA SET y EVALUATION OF THE SOLUTION
Kevin Julian Gonzalez Guerra	Investigador	● Aporté con fuentes de investigaciones locales. ● Aporté en la obtención de varios mapas con datos ● Realicé redacción de CASE STUDY y ETHICAL CONSIDERATIONS/QUESTIONS

Cesar Fabian Rincon Robayo	Experto, técnico	• Aporté la parte técnica (arquitecturas, pipelines, Google Earth Engine, APIs) • Conseguí buena parte de los datos consultando múltiples fuentes. • El Técnico(a) también aplica dado que ejecuté buena parte de los scripts. • Aporté en la redacción de Proposed neural based approach y Expected results.

1. REPOSITORIO

Organizacion de Github: https://github.com/Antioquia-Flood-AI

Fase 1: https://github.com/Antioquia-Flood-AI/antioquia-flood-mlp

Fase 2: https://github.com/Antioquia-Flood-AI/antioquia-flood-lstm

2. VIDEO

Proyecto Redes Neuronales - DIAPOS.pdf - Google Chrome 2026-02-24 18-28-12.m…

https://drive.google.com/file/d/1_5J2pZZZNiciE7c7A_2nMV4U86rc4UBN/view?usp=sharing

REFERENCIAS

[1] J. M. Moreno, J. M. Sánchez, y H. E. Espitia, “Use of computational intelligence techniques to predict flooding in places adjacent to the Magdalena River,” Heliyon, vol. 6, no. 9, p. e04872, sep. 2020.

[2] S. Cárdenas-Rodríguez, C. A. Vides-Herrera, y A. Pardo-García, “Sistema de alerta temprana de inundaciones para el río Arauca basado en técnicas de inteligencia artificial,” Rev. Investig. Desarro. Innov., vol. 12, no. 2, pp. 315-326, jul.-dic. 2022.

[3] D. T. Bui et al., “A novel hybrid approach based on a swarm intelligence optimized extreme learning machine for flash flood susceptibility modeling,” Catena, vol. 179, pp. 184-196, may. 2019.

[4] J. S. Niño Medina, M. J. Suarez Barón, y J. A. Reyes Suarez, “Application of Deep Learning for the Analysis of the Spatiotemporal Prediction of Monthly Total Precipitation in the Boyacá Department, Colombia,” Hydrology, vol. 11, no. 8, p. 127, ag. 2024.

[5] V. Dubey y R. Katarya, “FloodCNN-BiLSTM: Predicting flood events in urban environments,” Eng. Anal. Bound. Elem., vol. 177, p. 106277, abr. 2025.

[6] S. Dhankhar et al., “A deep spatiotemporal RaintoRiverNetwork for water level prediction and flood forecasting,” J. Hydrol. Reg. Stud., vol. 61, p. 102571, oct. 2025.

[7] X. Xiang, S. Guo, Z. Cui, L. Wang, y C.-Y. Xu, “Improving flood forecast accuracy based on explainable convolutional neural network by Grad-CAM method,” J. Hydrol., vol. 642, p. 131867, oct. 2024.

[8] Estimación de caudales en una cuenca tropical mediante modelación neuronal artificial basada en memoria hidrológica (L. O. Gonzalez Salcedo & L. D. . Blandón-López, Trans.). (2026). Ingeniería Y Competitividad, 28(1), e-20415199.

[9] Martínez, Hernán & Giraldo, Robinson & Alarcón, Jorge & Zapata, Gabriel. (2009). Geotechnical zonification of the Valle de Aburrá using artificial neural network.

[10] Z. Liao, Z. Chen, X. Li, y J. Yin, "A fast simulation method for urban pluvial flooding based on a hybrid machine learning model," *J. Hydrol.*, vol. 624, p. 129945, 2023.

[11] iGuide Summer School Team 5, "Flood Depth Prediction Using Multimodal Feature Routing with Real-World High Water Mark Data," University of Illinois Urbana-Champaign, 2025.

[12] IDEAM, "Catálogo Nacional de Estaciones Hidrometeorológicas," Datos Abiertos Colombia, 2024. [En línea]. Disponible: https://www.datos.gov.co/resource/s54a-sgyg.json

[13] DAGRAN - Gobernación de Antioquia, "Histórico de Emergencias Antioquia 1903-2025," 2025. [En línea]. Disponible: https://gobantioquia.maps.arcgis.com/apps/dashboards/63b454366f2a482697185d1e1fd7b5fa

[14] IDEAM, "Profundidad de Inundación TR 10/20/50/100 Años — Centros Poblados," Datos Abiertos Colombia, 2025.

[15] Perplexity AI (2026) - Búsqueda de artículos científicos - https://www.perplexity.ai

[16] Claude - Anthropic (2026) - Apoyo en redacción y organización de ideas técnicas https://claude.ai

[17] NotebookLM - Google (2026) - Síntesis y estructuración de información académica https://notebooklm.google.com.